

Projet d'économétrie – M1 EIF

Anna Bennaïm et Sacha Mace

Table des matières

1. Modélisation univariée.....	3
A) Représentations graphiques	3
B) Autocorrélogrammes simples et partiels	4
C) Stratégie séquentielle de TRU	5
1) Pour la série d'indice des prix	5
2) Pour la série du taux de chômage :	8
D) Recherche du modèle ARMA : série d'indice des prix	12
1) Evaluation du modèle à travers le balayage des critères AIC et BIC :	12
2) Estimation du modèle ARMA(1,3)	13
E) Prévision.....	17
2. Modélisation Multivariée.....	19
A) Estimation du modèle VAR.....	19
B) Relation de causalité, au sens de Granger.....	22
C) Analyse impulsion-réponse des choc sur les différentes variables	23
D) Test de cointégration de Johansen	28
Conclusion	29

Introduction

“Deux fermetures d’usines - Cholet et Vannes - et 1254 suppressions de postes chez Michelin, 2400 emplois supprimés chez Auchan. La France a connu, mardi, une journée noire pour l’emploi et renoué avec ses vieux démons, ceux des gros plans sociaux” Les Échos 05/11/2024

Alors que la France connaît actuellement de nombreuses fermetures d’emplois dans une période où les prix ne cessent d’augmenter malgré un léger ralentissement en cette fin d’année 2024, la question de la corrélation entre l’inflation et le chômage refait surface.

Cette question constitue un enjeu fondamental en économie, tant pour les décideurs publics que pour les analystes des dynamiques de marché. Dans ce projet, nous examinons ces deux indicateurs clés de la conjoncture économique en France, de 2004 à aujourd’hui, en mettant en lumière les interactions et interdépendances entre eux. Notre analyse se fonde notamment sur l’hypothèse de la courbe de Phillips, qui postule une relation inverse entre le taux de chômage et l’inflation dans le court terme. Selon cette théorie, une baisse du chômage entraînerait une hausse des salaires et, par extension, une augmentation de l’inflation. Cependant, l’influence de facteurs structurels et conjoncturels, notamment les récessions économiques, les politiques monétaires de la Banque Centrale Européenne, ou les changements dans les dynamiques du marché du travail, ont complexifié cette relation au fil des années.

Notre projet s’attachera donc à modéliser économétriquement cette corrélation pour mieux comprendre les déterminants et les limites de cette relation. Après avoir sélectionné des séries temporelles d’inflation et de chômage corrigées des variations saisonnières, nous procéderons à une analyse statistique et économétrique complète. Cette analyse inclura une modélisation univariée pour chacun des indicateurs, avant de tester un modèle multivarié de type VAR pour examiner leurs interactions. Nos objectifs sont de vérifier la stationnarité des séries, de déterminer le modèle le plus approprié pour représenter chaque série et de quantifier l’effet d’un choc sur une variable sur l’autre. Enfin, nous comparerons les résultats obtenus avec les attentes théoriques et les évolutions contemporaines de la relation inflation-chômage.

On vide l’environnement global et on importe les bibliothèques :

```
rm(list=ls()) # on vide l'environnement global

library(readxl)
library(urca)
library(forecast)

library(lmtest)

library(tseries)
library(vars)

library(lpirfs)
```



1. Modélisation univariée

A) Représentations graphiques

Nous avons importé les librairies readxl et urca afin de pouvoir réaliser notre projet. Nous importons la base excel sur laquelle nous allons réaliser tous nos tests :

```
plot(base$Dates, base$`Indice des Prix à la Consommation (IPC)`, type = "l", main = "Indice des Prix à la Consommation de 2004 à 2023", xlab = "Dates", ylab = "Indice des Prix à la Consommation (IPC)", col="blue")
```

```
plot(base$Dates, base$`Taux de chômage`, type = "l", main = "Taux de chômage au fil du temps", xlab = "Dates", ylab = "Taux de Chômage", col="blue")
```



Le premier graphique représente l'évolution de l'indice des prix à la consommation au fil du temps, de 2005 à 2023. Ce graphique nous indique que l'indice des prix à la consommation fluctue entre -0,5% et 5,9%. Après une relative stabilité avec quelques fluctuations entre 2005 et 2010, une baisse marquée est visible autour de 2009, probablement liée à la crise économique, avant une reprise vers 2011. Par la suite, l'IPC oscille de façon modérée jusqu'en 2020. À partir de cette date, l'indice connaît une forte hausse, reflétant des pressions inflationnistes accentuées, notamment en 2022. En 2023, l'indice commence à décroître, ce qui pourrait indiquer une détente des pressions inflationnistes, possiblement grâce à des mesures de politique monétaire visant à freiner l'inflation. Ce graphique met en évidence les effets des crises économiques et des politiques de reprise sur le niveau des prix.

Le deuxième graphique montre l'évolution du taux de chômage sur une période allant d'environ 2005 à 2023. On observe une tendance générale qui révèle des fluctuations importantes, suggérant une alternance entre des périodes de hausse et de baisse du chômage. Entre 2005 et 2010, le taux de chômage reste relativement stable avant d'augmenter rapidement à partir de la crise économique de 2008-2009, qui entraîne une hausse significative jusqu'en 2015, atteignant un pic autour de 11 %, ce qui pourrait correspondre à des effets prolongés de la crise et à un contexte économique difficile. Après ce pic, une tendance à la baisse commence, suggérant une reprise économique progressive jusqu'à environ 2020. Cependant, une autre hausse en 2020 est visible, sûrement dû à la crise liée à la pandémie de COVID-19. Enfin, à partir de 2021, le taux de chômage diminue à nouveau, indiquant une reprise post-pandémie, bien que des fluctuations persistent, ce qui reflète un certain niveau d'incertitude économique.

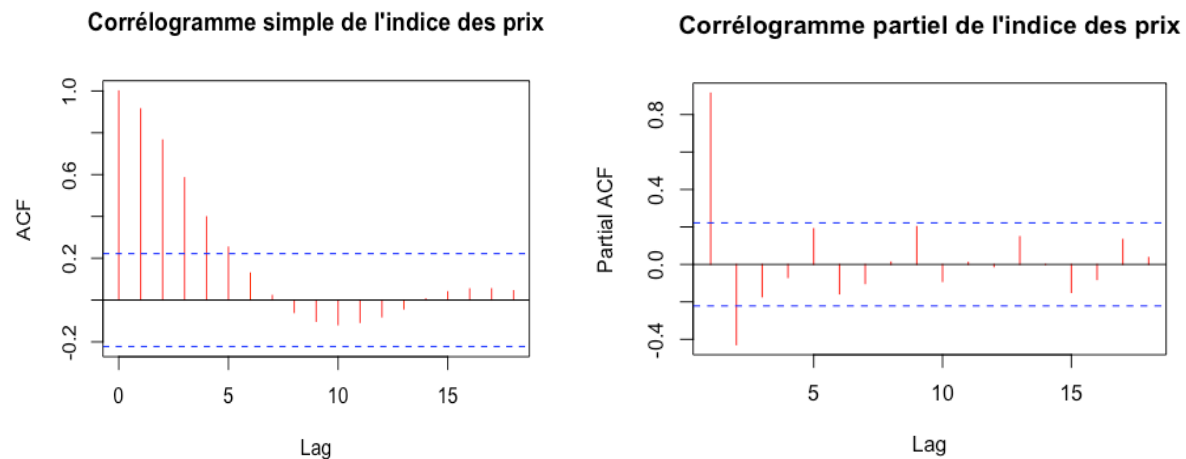
B) Autocorrélogrammes simples et partiels

Série de l'indice des prix à la consommation (IPC)

Commençons par représenter les corrélogrammes simple et partiel de L'indice de prix à la consommation :

```
acf( base$`Indice des Prix à la Consommation (IPC)`, main="Corrélogramme simple de l'indice des prix",col='red')
```

```
pacf(base$`Indice des Prix à la Consommation (IPC)`, main="Corrélogramme partiel de l'indice des prix",col='red')
```



Le corrélogramme simple décroît assez fortement jusque dans le négatif avant de remonter légèrement au-dessus de 0. On constate donc que le corrélogramme simple décroît avec h sous la forme d'une exponentielle. De plus, le corrélogramme partiel montre qu'il n'y a que les deux premières valeurs qui sont significatives, on peut dire que cette fonction d'autocorrélation décroît avec h sous la forme d'une sinusoïde amortie. Le comportement observé dans le ACF et le PACF suggère que cette série temporelle pourrait être modélisée par un processus ARIMA, possiblement un AR(1) ou un ARMA.


Les résultats nécessitent une vérification supplémentaire, avant d'implémenter un modèle précis.

Série du taux de chômage (TdC)

Passons maintenant à l'analyse des corrélogrammes simple et partiel du taux de chômage :

```
acf( base$`Taux de chômage`, main="Corrélogramme simple du taux de chômage",col='red')
```

```
pacf(base$`Taux de chômage`, main="Corrélogramme partiel du taux de chômage",col='red')
```



L'analyse de ces corrélogrammes est assez similaire à celle des précédents. En effet, on retrouve la même forme de chaque corrélogramme : le simple décroît sous forme exponentielle (même s'il est moins prononcé que celui pour l'IPC) et le partiel sous forme d'une sinusoïde amortie. Nous devons tout de même faire des tests plus poussés pour pouvoir quel processus est modélisé ici.

C) Stratégie séquentielle de TRU

Cette partie va nous servir à déterminer la stationnarité ou non de notre modèle en suivant une stratégie séquentielle. Pour cela, nous allons effectuer le test de Dickey Fuller augmenté (ADF) sur chaque série, pour savoir quel modèle est le plus adapté. Puis nous vérifierons le résultat avec le test KPSS.

1) Pour la série d'indice des prix à la consommation :

Test de Dickey Fuller Augmenté (ADF) :

Pour ce test, nous allons commencer par le modèle 3, qui est le plus général, afin de déterminer la présence d'une tendance déterministe et d'une constante. Le modèle s'écrit :

$$X_t = c + bt + \phi X_{t-1} + \sum_j \delta_j \Delta X_{t-j} + \epsilon_t$$

On fixe le nombre de retard à 4 car notre série est trimestrielle, ce qui signifie que nous examinerons les retards jusqu'à 4 trimestres en arrière pour détecter les tendances et les modèles de dépendance temporelle. On réalise, donc, le test de la racine unitaire.

Premièrement, nous posons les hypothèses :

$$\begin{cases} H_0 : \rho = 0 \\ H_1 : \rho < 0 \end{cases}$$

La statistique du test : $\hat{t}_{\hat{p}} = \frac{\hat{p}}{\hat{\sigma}_{\hat{p}}}$

Règle de décision : On rejette H_0 si et seulement si $\hat{t}_{\hat{p}} < VC$.

```
#Test M3
testM3 <-ur.df(y= base$`Indice des Prix à la Consommation (IPC)`, type="trend", lags=4, selectlags=
"AIC")
summary(testM3)
## Test regression trend
## Coefficients:
##      Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.163652  0.145024  1.128 0.26310
## z.lag.1    -0.161092  0.048522 -3.320 0.00145 **
## tt         0.002250  0.003155  0.713 0.47826
## z.diff.lag1 0.404668  0.114348  3.539 0.00073 ***
## z.diff.lag2 0.215003  0.125151  1.718 0.09036 .
##
## Value of test-statistic is: -3.32 3.6892 5.5335
##
## Critical values for test statistics:
##      1pct 5pct 10pct
## tau3 -4.04 -3.45 -3.15
## phi2  6.50  4.88  4.16
## phi3  8.73  6.49  5.47
```

Le test nous donne la statistique de test $\hat{t}_{\hat{p}}$ égale à -3,32. De plus nous remarquons qu'au seuil de 5%, la valeur critique (VC) équivaut à -3,45. Ainsi, $\hat{t}_{\hat{p}} > VC$: on ne rejette pas l'hypothèse nulle H_0 au seuil $\alpha = 5\%$. On en déduit que la série de données d'indice des prix présente une racine unitaire, indiquant une non-stationnarité.

Nous allons dès à présent faire le test de significativité du coefficient b avec les hypothèses suivantes :

$$\begin{cases} H_0: b = 0 \\ H_1: b \neq 0 \end{cases}$$

Statistique du test : $|\hat{t}_{\hat{b}}| = \frac{\hat{b}}{\hat{\sigma}_{\hat{b}}} = 0,713$

Règle de décision : On rejette H_0 si et seulement si $\hat{t}_{\hat{b}} > VC$.

Puisque nous avons une racine unitaire, on trouve la valeur critique sur la table de Dickey-Fuller, soit $VC = 3,14$.

On obtient donc, $\hat{t}_{\hat{b}} < VC$: on ne rejette pas l'hypothèse nulle H_0 au seuil $\alpha = 5\%$ et donc $b=0$.

Nous devons considérer un modèle plus contraint, le modèle 2, qui n'a pas de tendance déterministe :

$$X_t = c + \phi X_{t-1} + \sum_j \delta_j \Delta X_{t-j} + \epsilon_t$$

Nous allons réaliser le test de la racine unitaire sur le modèle 2 avec les hypothèses suivantes :

$$\begin{cases} H_0: \rho = 0 \\ H_1: \rho < 0 \end{cases}$$

La statistique de test : $\hat{t}_{\hat{\rho}} = \frac{\hat{\rho}}{\hat{\sigma}_{\hat{\rho}}}$

Le rejet de l'hypothèse H_0 intervient encore lorsque $\hat{t}_{\hat{\rho}} < VC$

```
testM2 <-ur.df(y= base$`Indice des Prix à la Consommation (IPC)`, type="drift", lags=4, selectlags="
AIC")
summary(testM2)
## Test regression drift
##
## Coefficients:
##      Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.24010   0.09730   2.468 0.016089 *
## z.lag.1     -0.15154   0.04647  -3.261 0.001726 **
## z.diff.lag1 0.40715   0.11389   3.575 0.000645 ***
## z.diff.lag2 0.21588   0.12470   1.731 0.087875 .
##
## Value of test-statistic is: -3.261 5.3174
##
## Critical values for test statistics:
##    1pct 5pct 10pct
## tau2 -3.51 -2.89 -2.58
## phi1  6.70  4.71  3.86
```

Le test nous donne une statistique de test égale à -3,26. La valeur critique au seuil de $\alpha = 5\%$ est de $VC = -2.89$. Ainsi, $\hat{t}_{\hat{\rho}} < VC$. Donc on rejette l'hypothèse H_0 au seuil $\alpha = 5\%$. On en déduit que la série de données d'indice des prix ne présente pas une racine unitaire, indiquant une stationnarité.

Testons maintenant la significativité de la constante c avec les hypothèses suivantes :

$$\begin{cases} H_0: c = 0 \\ H_1: c \neq 0 \end{cases}$$

La statistique de test : $|\hat{t}_{\hat{c}}| = \frac{\hat{c}}{\hat{\sigma}_{\hat{c}}} = 2,47$

On rejette H_0 si et seulement si $|\hat{t}_{\hat{c}}| > VC$.

On a rejeté l'hypothèse nulle de la racine unitaire, donc on lit la valeur critique dans la table de Student : au seuil $\alpha=5\%$, $VC = 1,96$. Ainsi, $|\hat{t}_{\hat{c}}| > VC$, on rejette donc bien H_0 et on s'arrête à ce modèle.

La série IPC suit un processus stationnaire de cette forme : $X_t \sim I(0) + c$

Test KPSS :

Nous nous sommes arrêtés au modèle 2 pour le test ADF, nous allons donc continuer avec ce modèle pour le test KPSS (type='mu').

Les hypothèses du test sont :

$$\begin{cases} H_0: \text{absence de racine unitaire} \\ H_1: \text{présence de racine unitaire} \end{cases}$$

La statistique de test : $LM = \frac{1}{s_T^2} \times \frac{\sum_{t=1}^T s_t^2}{T^2}$

On rejette l'hypothèse H_0 si $LM > VC$.

```
kpssM2<-ur.kpss(y=base$`Indice des Prix à la Consommation (IPC)`,type="mu",lags="short")
summary(kpssM2)
```

```
## Test is of type: mu with 3 lags.
##
## Value of test-statistic is: 0.3528
##
## Critical value for a significance level of:
##      10pct 5pct 2.5pct 1pct
## critical values 0.347 0.463 0.574 0.739
```

Nous remarquons que $LM = 0,3528$ et que la valeur critique est égale à $0,463$ au seuil $\alpha = 5\%$. Nous concluons que $LM < VC$: on accepte H_0 . Le processus est bien $I(0)$. Ce test confirme le résultat obtenu ultérieurement. On peut donc en déduire que notre processus est bien stationnaire.

2) Pour la série du taux de chômage :

La méthode est la même que pour la série de test sur la variable "Taux de chômage".

Test de Dickey Fuller Augmenté (ADF) :

Nous allons réaliser le test de la racine unitaire sur le modèle 3 avec les hypothèses suivantes:

$$\begin{cases} H_0: \rho = 0 \\ H_1: \rho < 0 \end{cases}$$

La statistique du test : $\hat{t}_{\hat{\rho}} = \frac{\hat{\rho}}{\hat{\sigma}_{\hat{\rho}}}$

```
testM3 <-ur.df(y= base$`Taux de chômage`, type="trend", lags=4, selectlags="AIC")
summary(testM3)
## Test regression trend
## Coefficients:
##      Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.641540 0.351957 1.823 0.0728.
## z.lag.1 -0.065546 0.038120 -1.719 0.0901.
## tt -0.001550 0.002042 -0.759 0.4504
## z.diff.lag1 -0.083796 0.120023 -0.698 0.4875
```



```
## z.diff.lag2 0.229306 0.119792 1.914 0.0599 .
## z.diff.lag3 0.178522 0.122081 1.462 0.1483
##
## Value of test-statistic is: -1.7194 1.1727 1.7546
##
## Critical values for test statistics:
##      1pct 5pct 10pct
## tau3 -4.04 -3.45 -3.15
## phi2 6.50 4.88 4.16
## phi3 8.73 6.49 5.47
```

On trouve une statistique de test égale à $-1,7194 > VC = -3,45$. Donc on accepte H_0 au seuil de 5% : Notre modèle comporte une racine unitaire, signe de non stationnarité.

On teste la significativité du coefficient b de notre modèle avec les hypothèses suivantes :

$$\begin{cases} H_0 : b = 0 \\ H_1 : b \neq 0 \end{cases}$$

On calcule notre statistique de test : $|\hat{t}_b| = \frac{\hat{b}}{\hat{\sigma}_b} = 0,759$

D'après la table de Dickey Fuller (car racine unitaire non rejeté) $VC = 3,14$.
Or : $|\hat{t}_b| = 0,759 < VC = 3,14$

Donc on ne rejette pas H_0 au seuil de 5% et on doit donc considérer un modèle plus contraint, sans tendance déterministe, le modèle 2 :

```
testM2 <-ur.df(y= base$`Taux de chômage`, type="drift", lags=4, selectlags="AIC")
summary(testM2)
## Test regression drift
## Coefficients:
##      Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.57601 0.34014 1.693 0.0949 .
## z.lag.1 -0.06528 0.03800 -1.718 0.0904 .
## z.diff.lag1 -0.07366 0.11891 -0.619 0.5377
## z.diff.lag2 0.24356 0.11794 2.065 0.0427 *
## z.diff.lag3 0.19124 0.12055 1.586 0.1173
##
## Value of test-statistic is: -1.718 1.4801
##
## Critical values for test statistics:
##      1pct 5pct 10pct
## tau2 -3.51 -2.89 -2.58
## phi1 6.70 4.71 3.86
```

On trouve une statistique de test égale à $-1,718 > VC = -2,89$. Donc on ne rejette pas H_0 au seuil de 5% : notre modèle comporte une racine unitaire.

On teste donc la significativité de notre constante c avec les hypothèses suivantes :

$$\begin{cases} H_0 : c = 0 \\ H_1 : c \neq 0 \end{cases}$$

On calcule notre statistique de test : $|\hat{t}_{\hat{c}}| = \frac{\hat{c}}{\hat{\sigma}_{\hat{c}}} = 1,693$

D'après la table de Dickey Fuller (car racine unitaire non rejeté) $VC = 2,86$.
Or : $|\hat{t}_{\hat{c}}| = 1.693 < VC = 2,86$

Donc on ne rejette pas H_0 au seuil de 5% et on doit donc considérer un modèle plus contraint, sans constante, le modèle 1 :

```
testM1 <-ur.df(y= base$`Taux de chômage`, type="none", lags=4, selectlags="AIC")
summary(testM1)
## Test regression none
##
## Coefficients:
##      Estimate Std. Error t value Pr(>|t|)
## z.lag.1   -0.001452  0.004739 -0.306  0.760
## z.diff.lag1 -0.076952  0.117267 -0.656  0.514
## z.diff.lag2  0.193141  0.117331  1.646  0.104
##
## Value of test-statistic is: -0.3063
##
## Critical values for test statistics:
##      1pct 5pct 10pct
## tau1 -2.6 -1.95 -1.61
```

On trouve une statistique de test égale à $-0,3063 > VC = -1,95$. Donc on ne rejette pas H_0 au seuil de 5%, cela nous indique donc que le processus est non-stationnaire.

On conclut donc que la série du taux de chômage à un processus $I(1)$ et d'après le cours il s'agit d'un processus DS sans dérive.

$$X_t \sim I(1)$$

Test KPSS :

On effectue le test KPSS avec le modèle 2 (c'est le modèle le plus proche de celui sur lequel nous avons abouti précédemment)

$$\begin{cases} H_0 : \text{absence de racine unitaire} \\ H_1 : \text{présence de racine unitaire} \end{cases}$$

La statistique de test : $LM = \frac{1}{s_T^2} \times \frac{\sum_{t=1}^T s_t^2}{T^2}$

```
kpss_TC_M2<-ur.kpss(y=base$`Taux de chômage`,type="mu",lags="short")
summary(kpss_TC_M2)
```

```
## # KPSS Unit Root Test #
## #####
##
```

```
## Test is of type: mu with 3 lags.
##
## Value of test-statistic is: 0.4312
##
## Critical value for a significance level of:
##      10pct 5pct 2.5pct 1pct
## critical values 0.347 0.463 0.574 0.739
```

Ce test nous donne une statistique de test LM égale à 0,4312. Or la valeur critique est égale à 0,463 au seuil de 5% : $LM < VC$. On aboutit donc à un non-rejet de H_0 au seuil de 5% et donc une absence de racine unitaire.

Il y a donc une contradiction avec le test ADF que nous avons fait juste avant. Mais cela peut arriver parfois.


Pour choisir notre modèle, nous allons donc nous baser sur notre intuition et sur le graphique. Au vu de la représentation graphique du taux de chômage, il paraît difficile de qualifier la série comme étant stationnaire. En effet, on n'observe pas une oscillation autour d'une valeur fixe sans tendance apparente à la hausse ou à la baisse.

Pour cette raison, nous retiendrons que le modèle n'est pas stationnaire.

Stationnarisation de la variable taux de chômage :

La différence première de la série taux de chômage, calculée avec la fonction `diff()` en R, mesure la variation entre chaque valeur successive de la série temporelle. Elle permet d'analyser la tendance de croissance ou de décroissance de la série. C'est méthode qui permet de stationnariser un processus DS sans dérive.

```
diff_TC <- diff(base$`Taux de chômage`)
plot(base$Dates[2:78],diff_TC, type="l", main = "Taux de chômage différencié", xlab = "Dates", ylab = "Taux de Chomage", col="blue")
```



On obtient un graphique qui semble bien plus représenter un processus stationnaire que le précédent. En effet, on observe une oscillation autour d'une valeur fixe sans tendance apparente à la hausse ou à la baisse.

D) Recherche du modèle ARMA : série d'indice des prix

Nous pouvons faire une conjecture à partir des corrélogrammes simple et partiel de cette série. La série ressemble à un processus AR ou ARMA, on va déterminer cela grâce aux différents tests.

1) Évaluation du modèle à travers le balayage des critères AIC et BIC :

```
matAIC <- matrix(0,5,5)
matBIC <- matrix(0,5,5)
for (i in 0:4){
  for (j in 0:4){
    ARMAij <- Arima(y= base$`Indice des Prix à la Consommation (IPC)`, order=c(i,0,j), method= "ML")
    matAIC[i+1,j+1] <- ARMAij$aic
    matBIC[i+1,j+1] <- ARMAij$bic
  }
}
rownames(matAIC) <- c('p=0', 'p=1', 'p=2', 'p=3', 'p=4')
colnames(matAIC) <- c('q=0', 'q=1', 'q=2', 'q=3', 'q=4')
rownames(matBIC) <- c('p=0', 'p=1', 'p=2', 'p=3', 'p=4')
colnames(matBIC) <- c('q=0', 'q=1', 'q=2', 'q=3', 'q=4')
print(matAIC)

##      q=0  q=1  q=2  q=3  q=4
## p=0 282.8022 197.3050 175.2391 130.8542 120.8640
## p=1 144.1283 135.7016 134.3002 113.8337 114.6383
## p=2 131.0129 134.9379 134.2932 114.8834 116.6124
## p=3 129.7954 130.7577 128.1342 116.8058 118.7971
## p=4 131.2325 124.2692 128.3493 116.9157 118.8489

print(matBIC)

##      q=0  q=1  q=2  q=3  q=4
## p=0 287.5156 204.3751 184.6659 142.6377 135.0043
## p=1 151.1984 145.1285 146.0838 127.9740 131.1352
## p=2 140.4398 146.7214 148.4335 131.3803 135.4661
## p=3 141.5790 144.8980 144.6312 135.6595 140.0075
## p=4 145.3728 140.7662 147.2030 138.1261 142.4160
```

Voici les critères d'information des processus ARMA(p,q). On identifie le ARMA(p,q) pour lequel ces critères sont minimaux. On en déduit que le processus qui minimise le critère AIC est le processus ARMA(1,3). De plus, le processus minimisant le critère BIC est aussi le

processus ARMA(1,3). Ainsi, les critères AIC et BIC convergent vers un modèle ARMA (1, 3) comme choix optimal.

2) Estimation du modèle ARMA(1,3)

Nous allons dès à présent, faire l'estimation du processus ARMA(1,3). Ce processus s'écrit, avec $p = 1$ et $q = 3$:

$$Y_t = c + \phi_1 Y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \theta_3 \varepsilon_{t-3}$$

Nous allons maintenant estimer les paramètres de ce modèle ARMA(1,3) en utilisant la méthode du maximum de vraisemblance.

```
ARMA1_3 <- Arima(y= base$`Indice des Prix à la Consommation (IPC)`, order= c(1,0,3))
ARMA1_3$coef

## ar1    ma1    ma2    ma3 intercept
## 0.5197773 0.8880320 0.8880310 0.9999956 1.6991099
```

Puisque nous sommes dans le cas d'un ARMA(1,3), nous devons calculer la constante telle que $m = E(X_t) = \frac{c}{1-\phi_1}$ donc $\hat{c} = \hat{m} \cdot (1 - \hat{\phi}_1)$.

Cela nous donne $\hat{c} = 1,69911 * (1 - 0.519777) = 0,81595114$.


Ainsi notre modèle ARMA(1,3) se note :

$$Y_t = 0,81595 + 0.51978 Y_{t-1} + \varepsilon_t - 0.8880 \varepsilon_{t-1} - 0.8880 \varepsilon_{t-2} - 0.9999 \varepsilon_{t-3}$$

Test de validation des racines des polynômes $\Phi(L)$ et $\Theta(L)$:

On vérifie que les racines du polynôme $\Phi(L)$ et $\Theta(L)$ satisfont bien les conditions de stationnarité :

```
autoplot(ARMA1_3)
```



En examinant les graphiques, nous pouvons constater que toutes les racines se trouvent à l'intérieur des cercles, indiquant la stationnarité et l'inversibilité du modèle.

Test de significativité individuelle des coefficients :

Les hypothèses :

$$\begin{cases} H_0: \phi_i = 0 \\ H_1: \phi_i \neq 0 \end{cases}$$

La statistique de test : $t_{\hat{\phi}_i} = \frac{\hat{\phi}_i - 0}{\hat{\sigma}_{\hat{\phi}_i}} \sim \mathcal{N}(0,1)$ car $T - K = 78 - 2 = 76 > 30$.

Règle de décision : On rejette H_0 si $|t_{\hat{\phi}_i}| > VC$ ou si le seuil $\alpha = 5\% > p\text{-value}$

```
coeftest(ARMA1_3)
```

```
##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1      0.519777  0.097470  5.3327 9.677e-08 ***
## ma1      0.888032  0.061302 14.4861 < 2.2e-16 ***
## ma2      0.888031  0.121919  7.2837 3.247e-13 ***
## ma3      0.999996  0.129888  7.6989 1.373e-14 ***
## intercept 1.699110  0.371728  4.5708 4.858e-06 ***
```

On constate donc que les 5 coefficients c , ϕ_1 , θ_1 , θ_2 et θ_3 ont une p-value inférieure à 5%. Ainsi, on rejette l'hypothèse nulle ce qui signifie que nos coefficients sont tous significatifs.

Maintenant nous allons vérifier que les résidus ϵ_t ne sont pas corrélés.

Test de Ljung Box sur les résidus :


Les hypothèses testées sont les suivantes :

$$\begin{cases} H_0: \rho_1 = \rho_2 = \dots = \rho_H = 0 \\ H_1: \exists j \in \{1, 2, \dots, H\} \text{ tel que } \rho_j \neq 0 \Leftrightarrow H_1 = \bar{H}_0 \end{cases}$$

La statistique de test est : $LB(H) = T(T+2) \sum_{h=1}^H \frac{\hat{\rho}_h^2}{T-h} \sim \chi^2(H-k)$ sous H_0 avec $k = 4$

La règle de décision : on rejette H_0 si $LB(H) > VC$ au seuil $\alpha = 5\%$

```
checkresiduals(ARMA1_3, lags=10)
```



```
## Ljung-Box test
## data: Residuals from ARIMA(1,0,3) with non-zero mean
## Q* = 4.7399, df = 6, p-value = 0.5776
## Model df: 4. Total lags used: 10
```

On remarque que $p\text{-value} = 0,5776 > 5\%$. Cela confirme le non-rejet de l'hypothèse nulle H_0 , ce qui suggère l'absence d'autocorrélation à l'ordre 10.

Test d'absence d'effets ARCH et Engle (test d'homoscédasticité)


Dans ce test, nous allons tester l'homoscédasticité des résidus pour savoir si la volatilité dépend ou non de la volatilité passée.

$$\hat{\epsilon}_t^2 = \alpha_0 + \alpha_1 \hat{\epsilon}_{t-1}^2 + \alpha_2 \hat{\epsilon}_{t-2}^2 + \dots + \alpha_q \hat{\epsilon}_{t-p}^2 + v_t$$

Tout d'abord, nous voulons déterminer le nombre maximal de retards testés :

```
acf(ARMA1_3$residuals^2)
```

```
pacf(ARMA1_3$residuals^2)
```



On remarque qu'après le huitième retard, plus aucun des retards n'est significatif. Donc on effectue le test avec 8 retards.

Les hypothèses sont les suivantes :

$$\begin{cases} H_0: \alpha_1 = \alpha_2 = \dots = \alpha_p = 0 \text{ (pas d'effet ARCH)} \\ H_1: \bar{H}_0 \text{ (effet ARCH)} \end{cases}$$

Statistique de test : $LM = (T - p) \cdot R^2 \xrightarrow{H_0} \chi_p^2$

```
library(FinTS)
ArchTest(ARMA1_3$residuals,lags=8,demean = FALSE)
## ARCH LM-test; Null hypothesis: no ARCH effects
##
## data: ARMA1_3$residuals
## Chi-squared = 8.5205, df = 8, p-value = 0.3843
```

On constate que la p-value est largement supérieure à 5% donc on ne rejette pas H_0 au seuil de 5%.

On aboutit donc sur une absence d'effet ARCH et donc sur une homoscédasticité des erreurs. Ce qui confirme le résultat obtenu précédemment avec le test de Ljung Box.

Test de normalité des résidus de Jarque Bera :

Nous effectuons maintenant le test de l'hypothèse de normalité des résidus. On va donc comparer les moments d'ordre 3 et 4 de la série à ceux d'une loi normale.

Les hypothèses testées sont :

$$\begin{cases} H_0: \text{la série des résidus } \epsilon \text{ suit une loi normale} \\ H_1: \text{la série des résidus } \epsilon \text{ ne suit pas une loi normale} \end{cases}$$

La statistique de test : $JB = \frac{T-k}{6} \left[\hat{S}^2 + \frac{1}{4} (\hat{K} - 3)^2 \right], \quad JB \sim \chi^2(2) \text{ sous } H_0$


La règle de décision : on rejette H_0 au seuil de $\alpha=5\%$ si $JB > VC$ ou si $p\text{-value} < \alpha$


```
jarque.bera.test(ARMA1_3$residuals)
```

```
##  
## Jarque Bera Test  
##  
## data: ARMA1_3$residuals  
## X-squared = 5.0429, df = 2, p-value = 0.08034
```

Ainsi, on obtient $p\text{-value}=8\% > \alpha = 5\%$. On ne rejette pas l'hypothèse nulle ce qui signifie que nos résidus sont normalement distribués. Ainsi, il n'est pas nécessaire d'ajouter une variable indicatrice.

```
gghistogram(ARMA1_3$residuals, add.normal = TRUE)
```



Cet histogramme nous confirme bien notre résultat pour le test de Jarque Bera. On remarque que l'histogramme se centre vers la courbe de la loi normale en orange. Cela illustre parfaitement la distribution normale des résidus.

E) Prévision

Les prévisions économétriques sont un outil essentiel pour anticiper les tendances futures, prendre des décisions éclairées et élaborer des stratégies efficaces dans divers domaines. Cela permet d'atténuer les incertitudes et d'améliorer la gestion, contribuant ainsi à la réussite d'un projet d'économétrie.

Nous effectuons les prévisions pour les horizons de 1 à 3 sur notre modèle :

$$Y_t = 0,81595 + 0.51978Y_{t-1} + \varepsilon_t - 0.8880\varepsilon_{t-1} - 0.8880\varepsilon_{t-2} - 0.9999\varepsilon_{t-3}$$

```
forecast_ARMA1_3<- forecast(ARMA1_3, h=3, level=95)  
forecast_ARMA1_3
```

##	Point Forecast	Lo 95	Hi 95
## 79	1.918186	1.0288280	2.807544
## 80	1.264191	-0.2635450	2.791928
## 81	1.650136	-0.4328322	3.733104

Nous remarquons que notre modèle ARMA(1,3) estime des valeurs positives pour les années suivantes. Ainsi l'indice de prix devrait diminuer globalement sur les 3 prochains trimestres avec des hausses et des baisses.

Soit $\hat{Y}_T(h) = \mathbb{E}(Y_{T+h} | I_T)$, nous allons écrire la prévision de chaque horizon pour la série sur l'indice de prix :

- Pour $h=1$:

$$\hat{Y}_T(1) = \mathbb{E}(0,81595 + 0,51978Y_T + \varepsilon_{T+1} - 0,8880\varepsilon_T - 0,8880\varepsilon_{T-1} - 0,9999\varepsilon_{T-2} | I_T)$$

Donc $\hat{Y}_T(1) = 0,81595 + 0,51978Y_T - 0,8880\varepsilon_T - 0,8880\varepsilon_{T-1} - 0,9999\varepsilon_{T-2} = 1,9122$

- Pour $h=2$:

$$\hat{Y}_T(2) = \mathbb{E}(0,81595 + 0,51978Y_{T+1} + \varepsilon_{T+2} - 0,8880\varepsilon_{T+1} - 0,8880\varepsilon_T - 0,9999\varepsilon_{T-1} | I_T)$$

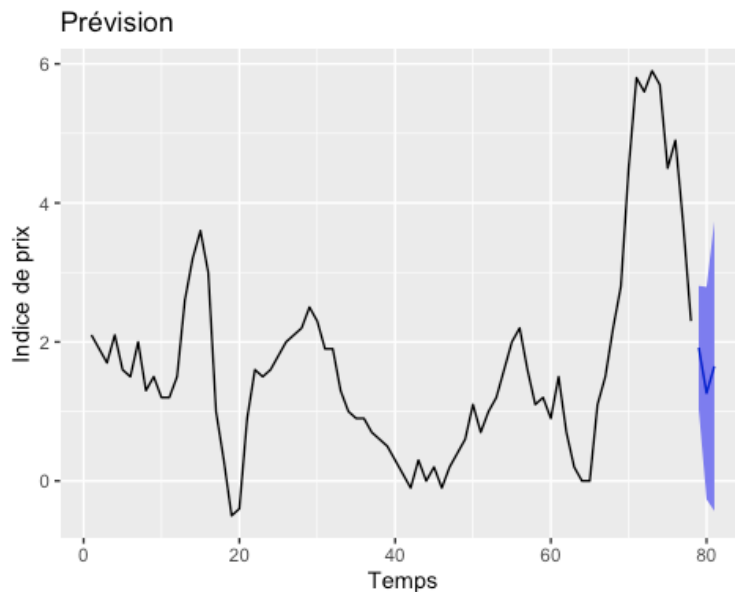
Donc $\hat{Y}_T(2) = 0,81595 + 0,51978\hat{Y}_T(1) - 0,8880\varepsilon_T - 0,9999\varepsilon_{T-1} = 1,2642$

- Pour $h=3$:

$$\hat{Y}_T(3) = \mathbb{E}(0,81595 + 0,51978Y_{T+2} + \varepsilon_{T+3} - 0,8880\varepsilon_{T+2} - 0,8880\varepsilon_{T+1} - 0,9999\varepsilon_T | I_T)$$

Donc $\hat{Y}_T(3) = 0,81595 + 0,51978\hat{Y}_T(2) - 0,9999\varepsilon_T = 1,6501$

`autoplot(forecast_ARMA1_3, main='Prévision', xlab='Temps', ylab='Indice de prix')`



On peut observer les prévisions dans la partie droite du graphique, colorée en bleu. La prévision centrale continue dans la direction de la tendance observée récemment, suggérant une augmentation légère de l'indice des prix pour les périodes futures proches. Cela pourrait

correspondre à une légère inflation ou à une reprise économique. Le modèle ARMA(1,3) semble bien s'adapter à la série d'indice des prix, et les prévisions produites sont cohérentes avec la structure des données historiques. L'élargissement des intervalles de confiance met en évidence l'incertitude inhérente à toute prévision, en particulier pour les horizons plus éloignés.

2. Modélisation Multivariée

L'objectif de cette partie est de modéliser plusieurs variables stationnaires en fonction de leur dynamique passée (modèle VAR).

A) Estimation du modèle VAR

Dans un premier temps, nous devons déterminer le nombre de retards optimal. Pour ce faire, nous allons utiliser les critères d'informations multivariés.

```
IPC <- ts(base$`Indice des Prix à la Consommation (IPC)`[2:78], frequency = 4, start = c(2005,1))
TdC <- ts(diff_TC, frequency = 4, start = c(2005,1))
```

#choix du nombre de retard optimal

```
endogen <- ts.intersect(IPC, TdC)
pselect <- VARselect(y = endogen, lag.max = 4, type = "const")
pselect
```

```
## $selection
## AIC(n) HQ(n) SC(n) FPE(n)
## 3 2 2 3
##
## $criteria
## 1 2 3 4
## AIC(n) -3.0242490 -3.25380610 -3.28518921 -3.20809665
## HQ(n) -2.9492254 -3.12876670 -3.11013404 -2.98302572
## SC(n) -2.8359921 -2.94004453 -2.84592301 -2.64332582
## FPE(n) 0.0485988 0.03864351 0.03747778 0.04053559
```

D'après le résultat des critères d'information, on a le choix entre 2 ou 3 retards. Nous choisissons 2 retards par simplification. On estime donc le modèle VAR(2) :

$$X_t = c + \Phi_1 X_{t-1} + \Phi_2 X_{t-2} + v_t$$

```
VAR2 <- VAR(y = endogen, type = "const", lag.max = 2)
summary(VAR2)
```

```
##
## VAR Estimation Results:
## =====
## Endogenous variables: IPC, TdC
## Deterministic variables: const
## Sample size: 75
```

```

## Log Likelihood: -79.721
## Roots of the characteristic polynomial:
## 0.7328 0.7328 0.4795 0.2198
## Call:
## VAR(y = endogen, type = "const", lag.max = 2)
##
##
## Estimation results for equation IPC:
## =====
## IPC = IPC.l1 + TdC.l1 + IPC.l2 + TdC.l2 + const
##
##      Estimate Std. Error t value Pr(>|t|)
## IPC.l1  1.29473   0.11433  11.325 < 2e-16 ***
## TdC.l1 -0.34754   0.17733  -1.960 0.053996 .
## IPC.l2 -0.41984   0.11396  -3.684 0.000448 ***
## TdC.l2  0.04331   0.18224   0.238 0.812846
## const  0.20197   0.09468   2.133 0.036415 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.5377 on 70 degrees of freedom
## Multiple R-Squared: 0.8756, Adjusted R-squared: 0.8684
## F-statistic: 123.1 on 4 and 70 DF, p-value: < 2.2e-16
##
##
## Estimation results for equation TdC:
## =====
## TdC = IPC.l1 + TdC.l1 + IPC.l2 + TdC.l2 + const
##
##      Estimate Std. Error t value Pr(>|t|)
## IPC.l1 -0.20939   0.07186  -2.914 0.00479 **
## TdC.l1 -0.13381   0.11146  -1.201 0.23396
## IPC.l2  0.23059   0.07163   3.219 0.00195 **
## TdC.l2  0.11103   0.11454   0.969 0.33574
## const -0.03599   0.05951  -0.605 0.54732
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.338 on 70 degrees of freedom
## Multiple R-Squared: 0.1693, Adjusted R-squared: 0.1219
## F-statistic: 3.567 on 4 and 70 DF, p-value: 0.01048
##
##
##
## Covariance matrix of residuals:
##      IPC    TdC
## IPC  0.28917 -0.00738
## TdC -0.00738  0.11424

```

```
##
## Correlation matrix of residuals:
##      IPC      TdC
## IPC 1.00000 -0.04061
## TdC -0.04061 1.00000
```

On constate que le coefficient de détermination pour l'IPC (0.8756) est largement supérieur à celui du Taux de Chômage (0.1693).

Pour l'équation de l'IPC, ICP.l1, ICP.l2 et la constante sont significatifs ; TdC.l1 et TdC.l2 ne le sont pas.

Pour l'équation de TdC, c'est quasiment le même constat, à une exception près. En effet, la constante n'est pas significative. On en déduit que les retards de ICP influencent significativement TdC. Le taux de chômage est donc significativement influencé par l'indice des prix à la consommation comme le suggère la théorie avec la courbe de Phillips. En revanche les retards de TdC n'ont pas d'effet important sur TdC. Économiquement, cela suggère que les politiques économiques ou monétaires visant à réduire le chômage pourraient être plus efficaces si elles influencent directement les variables économiques sous-jacentes (comme celles capturées par ICP) plutôt que de simplement se baser sur l'inertie du chômage lui-même.

On vérifie que le VAR est bien stationnaire en interrogeant sur la valeur des racines inverses :

```
roots(VAR2)
## [1] 0.7327929 0.7327929 0.4794562 0.2198414
```

Les modules des inverses des racines du polynôme caractéristique valent 0.9109 et 0.09889578. Donc elles sont inférieures à 1, démontrant la stationnarité du modèle AR(2).

On vérifie que les résidus ne sont pas auto-corrélés. On choisit de tester l'autocorrélation sur 10 retards :

```
serial.test(VAR2, lags.pt = 10, type = "PT.adjusted")
##
## Portmanteau Test (adjusted)
##
## data: Residuals of VAR object VAR2
## Chi-squared = 35.63, df = 32, p-value = 0.3014
```

On constate que la p-value est égale à 0,3014 > 5%. On ne rejette donc pas l'hypothèse d'absence d'autocorrélation des résidus. Il n'y donc pas de corrélation significative des résidus au seuil de 5%.

```
coef_VAR2 <- Acoef(VAR2)
coef_VAR2
```

```
## [[1]]
##      IPC.l1  TdC.l1
## IPC 1.2947258 -0.347542
## TdC -0.2093926 -0.133814
##
## [[2]]
##      IPC.l2  TdC.l2
## IPC -0.4198428 0.04331005
## TdC 0.2305930 0.11102628
```

Nous pouvons donc écrire l'estimation de notre VAR sous la forme matricielle suivante :

$$\begin{pmatrix} IPC_t \\ TdC_t \end{pmatrix} = \begin{pmatrix} 1.2947258 & -0.4198428 \\ -0.2093926 & 0.2305930 \end{pmatrix} \begin{pmatrix} IPC_{t-1} \\ TdC_{t-1} \end{pmatrix} + \begin{pmatrix} -0.347542 & 0.04331005 \\ -0.133814 & 0.11102628 \end{pmatrix} \begin{pmatrix} IPC_{t-2} \\ TdC_{t-2} \end{pmatrix} + \begin{pmatrix} \epsilon_{IPC_{t-2}} \\ \epsilon_{TdC_{t-2}} \end{pmatrix}$$

B) Relation de causalité, au sens de Granger

Nous voulons maintenant savoir si une de nos séries est causale, c'est à dire si elle contient de l'information pour prévoir notre autre série. Au sens de Granger, nous allons voir si la connaissance des valeurs passées d'une améliore la prévision de l'autre.

Nous allons donc vérifier si la série d'indice des prix à la consommation (IPC) cause ou non le taux de chômage (TdC), au sens de Granger.

Soit notre modèle VAR(2) de dimension 2 :

$$\begin{cases} IPC_t = c + \alpha_1 IPC_{t-1} + \beta_1 TdC_{t-1} + \alpha_2 IPC_{t-2} + \beta_2 TdC_{t-2} + v_{1t} \\ TdC_t = c' + \alpha_1' IPC_{t-1} + \beta_1' TdC_{t-1} + \alpha_2' IPC_{t-2} + \beta_2' TdC_{t-2} + v_{2t} \end{cases}$$

Les hypothèses de ce test sont :

$$\begin{cases} H_0: \alpha_1' = \alpha_2' = 0 \text{ donc que IPC ne cause pas TdC} \\ H_1: \text{un des } \alpha' \text{ est différent de 0 et donc IPC cause TdC} \end{cases}$$

La statistique de test s'écrit : $F = \frac{SCR_0 - SCR_1}{\frac{SCR_1}{T' - 2p - 1}} \rightarrow F(p, T' - 2p - 1)$

Avec : $\begin{cases} T' = T - p = 76 \\ SCR_0 : \text{la SCR du modèle sous } H_0 \\ SCR_1 : \text{la SCR sous } H_1 \end{cases}$

On rejette l'hypothèse nulle si $F > VC$ ou si $\alpha > p\text{-value}$ avec un seuil à $\alpha = 5\%$.

On test d'abord s'il y a une causalité de l'indice des prix à la consommation vers le taux de chômage :

```
TCIPC <- causality(VAR2, cause = "IPC")
TCIPC$Granger
```

```
##
## Granger causality H0: IPC do not Granger-cause TdC
##
## data: VAR object VAR2
## F-Test = 5.1986, df1 = 2, df2 = 140, p-value = 0.00664
```

D'après ce test, nous avons $p\text{-value} = 0,664\% < 5\%$. On rejette l'hypothèse nulle au niveau de confiance 95%. On en conclut que l'indice des prix à la consommation (IPC) cause le taux de chômage (TdC) au sens de Granger. Cela indique qu'il y a une relation de causalité temporelle entre les deux séries, où les valeurs passées d'IPC peuvent être utilisées pour prédire les valeurs futures de TdC. De plus, testons s'il y a une causalité du taux de chômage vers l'indice des prix à la consommation :

```
TCTdC <- causality(VAR2, cause = "TdC")
TCTdC$Granger

##
## Granger causality H0: TdC do not Granger-cause IPC
##
## data: VAR object VAR2
## F-Test = 2.0598, df1 = 2, df2 = 140, p-value = 0.1313
```

Nous obtenons donc une $p\text{-value} = 13\% > 5\%$. Il n'y a pas de rejet de H_0 . On en conclue donc que le taux de chômage ne cause pas l'indice des prix à la consommation au sens de Granger, c'est à dire que les valeurs passées de TdC ne peuvent être utilisées pour prédire les valeurs futures de IPC.

Ainsi, pour conclure, le test de Granger, nous a bel et bien montré qu'il y avait une causalité temporelle entre les deux séries. En effet, la série IPC cause la série TdC car la connaissance de ses valeurs passées améliore la prévision du taux de chômage. Cela peut refléter des dynamiques économiques comme la relation entre inflation et chômage (courbe de Phillips), où une hausse de l'IPC peut signaler une économie en expansion, réduisant le chômage à court terme. À l'inverse, une inflation excessive pourrait diminuer le pouvoir d'achat, affectant la demande et l'emploi. Ce résultat guide les politiques économiques et améliore les modèles de prévision.

C) Analyse impulsion-réponse des chocs sur les différentes variables

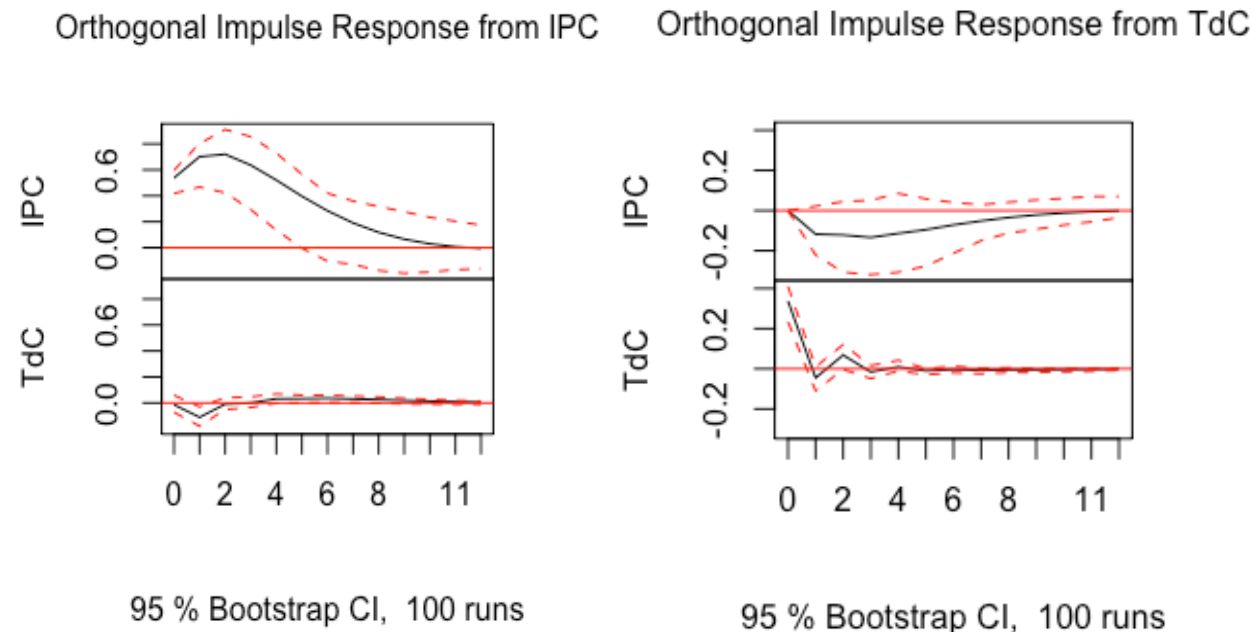
La fonction de réponse d'un VAR retrace l'effet d'un choc en T sur l'une des variables sur les valeurs présentes et futures de cette variable et des autres variables du VAR.

$$IR(t, h, di) = \mathbb{E}(X_{t+h} \mid v_t = di, I_t) - \mathbb{E}(X_{t+h} \mid v_t = 0, I_t)$$

On applique d'abord le calcul des réponses fondées sur des prévisions récursives avec le VAR estimé. Les chocs structurels sont obtenus avec une décomposition de Cholesky. Pour déterminer l'ordre, nous utilisons les résultats du test de causalité au sens de Granger. Puisqu'il existe une relation de causalité de l'indice des prix à la consommation sur le taux de chômage, nous plaçons le taux de croissance du PIB l'indice des prix à la consommation en première position pour la décomposition de Cholesky.

Méthodes des VAR

```
endogen2 <- ts.intersect(IPC, TdC)
VAR2CHOLESKY <- VAR(y=endogen2, type='const', lag.max=2)
irf<-irf(VAR2CHOLESKY,n.ahead = 12,ortho = TRUE,ci=0.95)
plot(irf)
```



On constate que lorsqu'il y a un choc sur l'indice des prix, le taux de chômage a une réaction opposée au choc et de moins grande amplitude. La réponse au choc intervient dans une période après le choc. L'intervalle de confiance est assez resserré ce qui indique une précision des résultats.

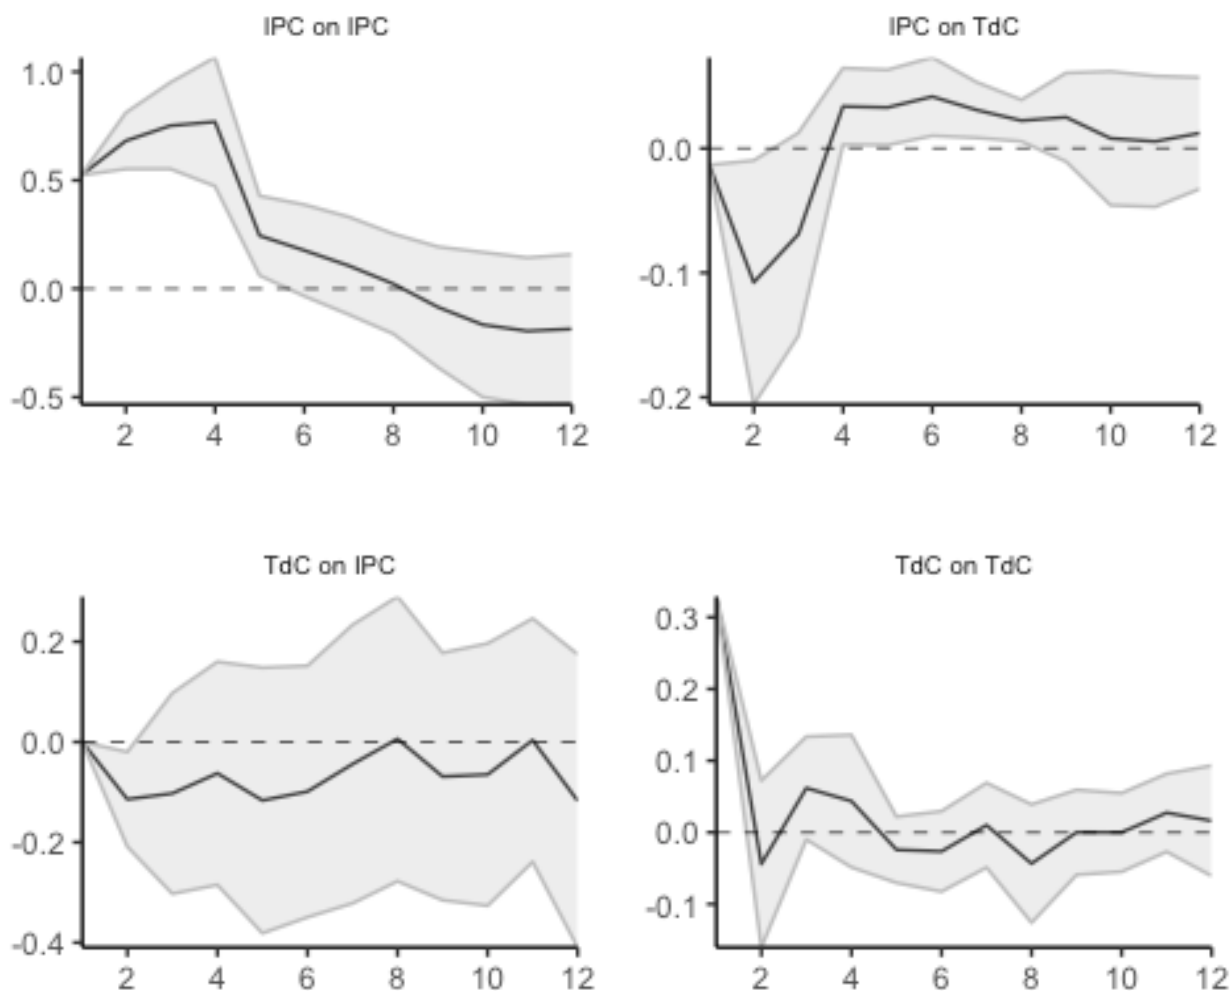
En revanche, pour ce qui est du choc sur le taux de chômage, la réaction de l'IPC est assez imprécise avec un intervalle de confiance assez large. Cela montre une plus grande incertitude autour de cette réponse et peut indiquer que le modèle n'explique pas la causalité du taux de chômage envers l'indice des prix à la consommation, ce qui va dans le sens des résultats obtenus à l'issue du test précédent.

Dans les deux cas, le choc positif sur une variable semble entraîner une réaction négative sur l'autre variable. Cela confirme encore une fois la théorie macroéconomique sous-jacente qui stipule l'existence d'une relation inverse entre chômage et inflation.'

Méthode des projections locales de Jorda :

On fait ensuite le calcul des réponses fondés sur la méthode des projections locales de Jorda. Les chocs structurels sont obtenus avec une décomposition de Cholesky.

```
irf_LP <- lp_lin(endog_data = as.data.frame(endogen2),  
  lags_endog_lin = NaN,  
  lags_criterion = 'BIC',  
  max_lags = 2,  
  trend = 0,  
  shock_type = 0,  
  confint=1.96,  
  hor=12,  
  adjust_se=TRUE)  
plot(irf_LP)
```



- IPC sur TdC :

Les graphiques de la première ligne présentent les réponses des indices de prix à la consommation et du taux de chômage à un choc affectant les indices de prix à la consommation. Après un choc positif sur l'IPC, le TdC (chômage) réagit négativement, ce qui est cohérent avec la théorie économique (courbe de Phillips). Après environ 6 périodes, la réponse tend à s'atténuer et converge vers zéro. Bien que les intervalles de confiance soient présents, ils ne sont pas excessivement larges (Relativement aux intervalles de confiance du graphique : TdC sur IPC), ce qui donne une certaine robustesse aux résultats. TdC répond instantanément à IPC. Le classement retenu est donc bien IPC puis TdC ce qui est cohérent avec le test de Granger.

- Tdc sur IPC :

Les graphiques de la seconde ligne présentent les réponses des indices de prix à la consommation et du taux de chômage à un choc affectant le taux de chômage.

Suite à un choc positif sur le taux de chômage, l'IPC réagit d'abord négativement, mais montre une forte fluctuation par la suite. Les intervalles de confiance sont beaucoup plus larges, reflétant une incertitude accrue. Cela peut indiquer que d'autres variables ou dynamiques influencent cette relation.

Analyse de la variance :


Nous allons maintenant étudier la décomposition de la variance dans notre modèle. Cela va nous aider à savoir si nous avons fait le bon choix de l'ordre des variables dans la décomposition de Choleski.

```
dec_var <- fevd(VAR2CHOLESKY, n.ahead=15)
print(dec_var)
```

```
## $IPC
##      IPC      TdC
## [1,] 1.0000000 0.0000000
## [2,] 0.9826584 0.01734162
## [3,] 0.9784739 0.02152607
## [4,] 0.9734351 0.02656493
## [5,] 0.9707827 0.02921732
## [6,] 0.9688728 0.03112717
## [7,] 0.9678050 0.03219502
## [8,] 0.9671935 0.03280651
## [9,] 0.9668977 0.03310234
## [10,] 0.9667676 0.03323238
## [11,] 0.9667219 0.03327814
## [12,] 0.9667105 0.03328949
## [13,] 0.9667104 0.03328961
## [14,] 0.9667121 0.03328793
## [15,] 0.9667129 0.03328709
##
## $TdC
##      IPC      TdC
## [1,] 0.001648862 0.9983511
```

```
## [2,] 0.096905427 0.9030946
## [3,] 0.094141471 0.9058585
## [4,] 0.093967101 0.9060329
## [5,] 0.100682521 0.8993175
## [6,] 0.107960933 0.8920391
## [7,] 0.116465022 0.8835350
## [8,] 0.122457111 0.8775429
## [9,] 0.126565888 0.8734341
## [10,] 0.128850860 0.8711491
## [11,] 0.130033121 0.8699669
## [12,] 0.130552837 0.8694472
## [13,] 0.130752461 0.8692475
## [14,] 0.130812314 0.8691877
## [15,] 0.130824202 0.8691758
```

`plot(dec_var)`



La part du taux de chômage dans la variance de l'indice des prix à la consommation est très faible, voire nulle. À l'inverse, la part de l'indice des prix à la consommation dans la variance du taux de chômage est un peu plus élevée. Cela confirme bien la relation de causalité de l'indice des prix à la consommation vers le taux de chômage, justifiant notre choix d'ordre pour la décomposition de Cholesky.

Les conclusions tirées de l'analyse des réponses impulsives des chocs sur nos 2 variables, obtenues, grâce aux deux méthodes utilisées, concordent avec la manière dont le choc a été généré via la décomposition de Cholesky, et sont également cohérentes avec les tests de causalité au sens de Granger.

D) Test de cointégration de Johansen

Le test de cointégration de Johansen permet de mettre en évidence l'existence de relations de cointégration entre plusieurs séries temporelles. On s'intéresse donc à la présence de relations de long terme entre les variables. Les hypothèses de ce test sont :

$$\begin{cases} H_0 = r \leq k \\ H_1 = r > k \end{cases}$$

avec r le rang de la matrice variance-covariance

La statistique de test : $TR = -T \sum_{i=k+1}^n \ln(1 - \lambda_i)$

La règle de décision nous indique que nous rejetons l'hypothèse nulle H_0 si $TR > VC$ où VC est la valeur au seuil 5% tabulée par Johansen et Juselius.

Ce test doit être fait sur des séries $I(1)$. Le test de Johansen suppose que toutes les séries sont intégrées du même ordre, ce qui signifie qu'elles ont la même propriété d'ordre d'intégration. Dans le cas de notre projet, nous ne pouvons pas effectuer ce test. En effet, ayant une série temporelle qui suit un modèle $I(0) + C$ et une autre $I(1)$, nous ne pouvons pas trouver de résultats intéressants de cointégration.

N'ayant pu effectuer le test de Johansen à cause de nos séries temporelles, nous ne pouvons pas estimer le VECM puisqu'il n'existe pas de relation de cointégration entre nos deux variables.

Conclusion

Pour conclure, ce projet visait à étudier la relation entre l'inflation et le chômage en France sur la période 2004-2023, en utilisant les séries temporelles d'indice des prix à la consommation (IPC) et du taux de chômage (TdC). Les tests économétriques effectués, basés sur des modèles univariés et multivariés, ont révélé des dynamiques intéressantes. D'un point de vue univarié, les tests réalisés sur l'indice des prix à la consommation et le taux de chômage ont permis d'établir leurs propriétés statistiques. L'analyse des tests ADF et KPSS a montré que l'IPC est stationnaire à un niveau constant $I(0)$, tandis que le taux de chômage est un processus non stationnaire $I(1)$, un processus DS sans dérive plus précisément. Ces conclusions, nous ont permis pour l'IPC d'identifier un modèle ARMA(1,3), stationnaire, pour lequel tous les coefficients sont significatifs. Concernant ses résidus, les tests montrent qu'ils suivent une loi normale et ne présentent pas d'effets ARCH. Les prévisions réalisées indiquent une légère baisse de l'inflation dans les trimestres à venir, avec des variations modérées. Ces résultats suggèrent une dynamique cohérente avec les fluctuations économiques récentes.

Du côté du modèle multivarié, les tests de causalité de Granger ont mis en évidence une relation temporelle unidirectionnelle : l'IPC cause le taux de chômage, mais l'inverse n'a pas été observé. Cela correspond à la théorie économique où l'inflation, par ses effets sur les salaires réels et la demande, peut influencer l'emploi. Les fonctions de réponse impulsionnelle ont confirmé cet effet à court terme. Cependant, l'absence de relation de cointégration entre les deux variables indique que cette influence ne s'étend pas sur le long terme.

D'un point de vue économique, ces résultats sont cohérents avec le contexte français. Les chocs économiques récents, comme la crise du COVID-19 ou les tensions géopolitiques, ont exercé une pression notable sur les prix et l'emploi, reflétant les relations complexes entre inflation et chômage. Enfin, bien que les modèles développés offrent des pistes intéressantes, ils ne capturent pas tous les aspects des dynamiques économiques sous-jacentes. Des recherches futures, intégrant davantage de variables explicatives ou des horizons temporels plus longs, pourraient enrichir ces analyses et fournir des outils plus robustes pour la prise de décision économique.